Evidencia de aprendizaje 2. Creación de una base de datos de Staging

Omar Octavio Fortich Almanza

Institución Universitaria Digital de Antioquia

PREICA2601B010048: Bases de Datos II

Docente: Antonio J. Valderrama J.

29 de marzo de 2026

Introducción

En la arquitectura de Inteligencia de Negocios (BI), la consolidación de información proveniente de sistemas transaccionales es un pilar fundamental para la toma de decisiones basadas en datos. El presente documento detalla la creación de una base de datos de *Staging* fundamentada en el modelo relacional "Jardinería". La zona de *Staging* actúa como un área de preparación temporal donde los datos extraídos del sistema origen aterrizan antes de ser transformados y cargados en un *Data Warehouse*. Este proceso aísla las consultas analíticas pesadas, asegurando la integridad y el rendimiento del sistema operativo en tiempo real, al mismo tiempo que permite una primera capa de depuración enfocada en seleccionar exclusivamente los datos con valor analítico.

Objetivos

Objetivo General: Diseñar e implementar una base de datos de *Staging* optimizada a partir del modelo relacional transaccional corregido de la empresa "Jardinería".

Objetivos Específicos: Analizar las estructuras del modelo origen para seleccionar y aislar exclusivamente los atributos con relevancia dimensional y de hechos.

- Construir consultas SQL (DDL y DML) para la homologación de tablas y la extracción masiva de registros.
- Validar la integridad de los datos cargados mediante consultas de auditoría y asegurar los entornos mediante copias de respaldo (Backups).

Planteamiento del problema

La base de datos "Jardinería" opera bajo un modelo OLTP (Procesamiento Transaccional en Línea) diseñado para la inserción y gestión diaria de oficinas, empleados, clientes, inventario de productos y facturación. Ejecutar procesos de transformación (ETL) o consultas agregadas directamente sobre este entorno puede saturar los recursos del servidor y afectar la operación del negocio. Además, el modelo incluye metadatos y campos de texto extenso, como descripciones en HTML o números de fax, que incrementan severamente el volumen de almacenamiento, pero carecen de utilidad para la generación de métricas y cuadros de mando analíticos. Se requiere una estrategia de extracción selectiva hacia un entorno de *Staging* optimizado.

```sql
-- 1. Ver todas las tablas de la base de datos
SELECT TABLE_NAME
FROM INFORMATION_SCHEMA.TABLES
WHERE TABLE_TYPE = 'BASE TABLE';

-- 2. Ver las columnas, tipos de datos y si aceptan nulos de una tabla específica
SELECT COLUMN_NAME, DATA_TYPE, CHARACTER_MAXIMUM_LENGTH
FROM INFORMATION_SCHEMA.COLUMNS
WHERE TABLE_NAME = 'cliente';

-- 3. Ver un resumen completo de todas las tablas y sus columnas
SELECT TABLE_NAME, COLUMN_NAME, DATA_TYPE
FROM INFORMATION_SCHEMA.COLUMNS
ORDER BY TABLE_NAME, ORDINAL_POSITION;
```

00 % No issues found

Results | Messages

	TABLE_NAME
1	oficina
2	empleado
3	Categoria_producto
4	cliente
5	pedido
6	producto
7	detalle_pedido
8	pago

	COLUMN_NAME	DATA_TYPE	CHARACTER_MAXIMUM_LENGTH
1	ID_cliente	int	NULL
2	nombre_cliente	varchar	50
3	nombre_contacto	varchar	30
4	apellido_contacto	varchar	30
5	telefono	varchar	15
6	fax	varchar	15
7	linea_direccion1	varchar	50
8	linea_direccion2	varchar	50

	TABLE_NAME	COLUMN_NAME	DATA_TYPE

Análisis del problema

Durante el análisis estructural y ejecución del script original del sistema "Jardinería", se observó un modelo de ocho tablas normalizadas. Sin embargo, se identificaron múltiples errores lógicos y de integridad en los datos de origen que impedían la instanciación correcta de la base de datos transaccional, los cuales debían resolverse antes de pensar en un entorno de *Staging*:

Conflictos en el orden de inserción: El script original intentaba insertar registros dependientes antes que sus registros "padre" (por ejemplo, registrar empleados sin que existieran las oficinas, o asignar pedidos a clientes inexistentes). Esto generaba violaciones directas a las restricciones de llaves foráneas (FOREIGN KEY).

Inconsistencia en tipos de datos: En la tabla producto, la columna Categoria estaba definida con un tipo de dato numérico (INT), pero las sentencias de inserción intentaban introducir cadenas de texto (como 'Herramientas' o 'Frutales'), lo que provocaba fallos de conversión de datos por parte del motor SQL.

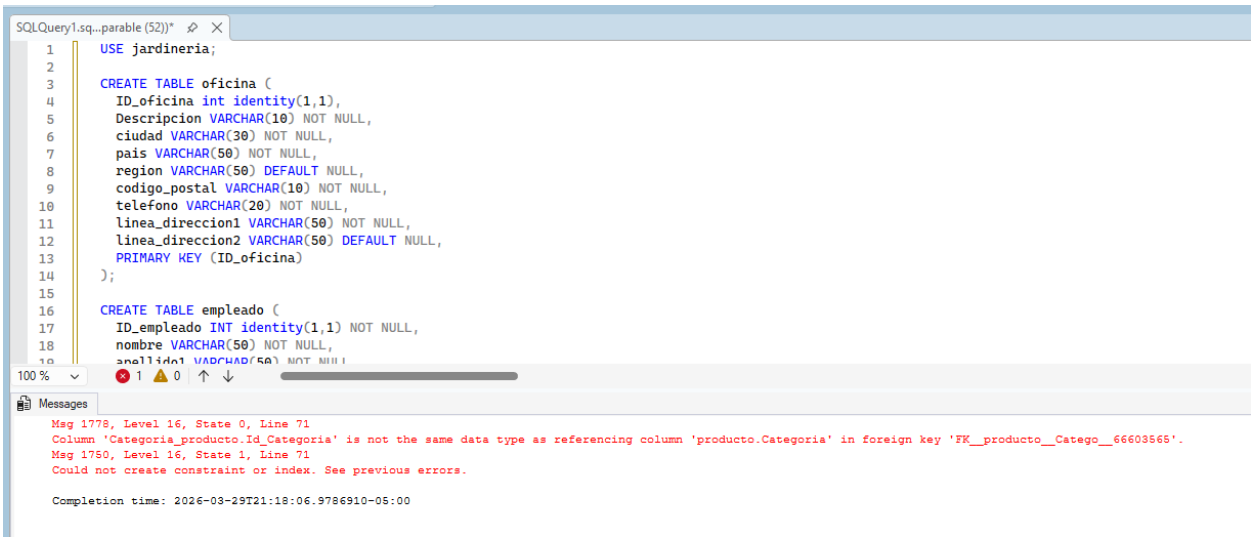

Riesgo de datos truncados: Se detectó que la columna ID_producto (presente en las tablas producto y detalle_pedido) poseía una longitud restrictiva de VARCHAR(15). Algunos códigos o nombres en el origen tenían el potencial de exceder esta longitud, arriesgando la pérdida de caracteres.

Por otro lado, pensando en el entorno analítico, trasladar las restricciones de integridad referencial a un entorno de *Staging* generaría latencia e ineficiencia durante la carga masiva. Además, se identificó información operativa sin valor analítico: código HTML (descripcion_html), descripciones botánicas extensas en formato TEXT, y datos de contacto de bajo nivel (faxes, extensiones, líneas de dirección exactas). Conservar estas columnas comprometería el rendimiento de futuros modelos dimensionales.

Propuesta de la solución

Para resolver la problemática expuesta, el proceso se dividió en dos grandes fases: la corrección del modelo transaccional de origen y la posterior extracción selectiva hacia la base de datos staging_jardineria.

Correcciones al modelo de origen

Antes de migrar la información, se aplicaron correcciones críticas al script fuente de la base de datos transaccional:

- Se reordenaron jerárquicamente las sentencias INSERT para respetar las llaves foráneas, garantizando que las oficinas se crearan antes que los empleados, y los clientes antes que los pedidos.
- Se realizó una limpieza de datos para sustituir los valores de texto en la columna Categoria de los productos por sus respectivos identificadores numéricos exactos, resolviendo el conflicto de tipos de datos.

- Se mantuvo la coherencia de la longitud de VARCHAR(15) para la columna ID_producto, pero se implementaron validaciones lógicas para asegurar que los identificadores coincidieran exactamente entre las tablas origen sin sufrir truncamiento.

Descripción del análisis y traslado a la base de datos Staging

Una vez estabilizado el origen, se construyó el entorno staging_jardineria. Las instrucciones de creación de este entorno se diseñaron omitiendo las cláusulas FOREIGN KEY y las propiedades autoincrementales (IDENTITY) para permitir la inyección directa de los identificadores exactos del sistema origen, preservando la trazabilidad de cada registro.

Se incorporó una columna de auditoría, fecha_carga, en todas las tablas para registrar la marca de tiempo de la extracción. Las columnas de texto extenso e información de contacto aislada fueron omitidas. Sin embargo, las tablas de hechos (pedido, detalle_pedido y pago) se replicaron de forma íntegra para no perder la granularidad de las métricas financieras. La extracción se materializó a través de instrucciones INSERT INTO ... SELECT mapeadas exclusivamente a los atributos depurados. Finalmente, se desarrollaron consultas de validación comparando las volumetrías (COUNT(*)) entre ambos entornos, certificando una migración exitosa antes de asegurar la base de datos a través de los archivos de respaldo (.bak).

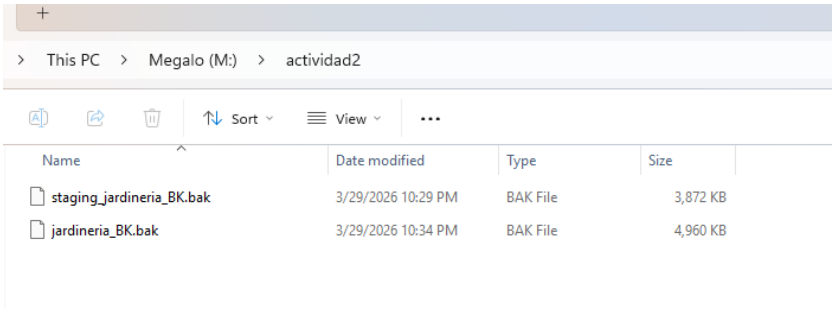

Bibliografía

Kimball, R., & Ross, M. (2013). The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling (3.ª ed.). Wiley.